

エネルギー保存則など 望ましい性質を持つ 深層学習の設計について

松原 崇（大阪大学）

深層学習とは

目的汎関数 \mathcal{L} と関数空間 \mathcal{F} を
目的に合わせて設計する研究領域である

$$\inf_{f \in \mathcal{F}} \mathcal{L}(f, \{X, Y\})$$

\mathcal{L} : ネットワークの入出力を変形する

\mathcal{F} : ネットワーク構造で決める

深層学習とは

目的汎関数 \mathcal{L} と関数空間 \mathcal{F} を
目的に合わせて設計する研究領域である

$$\inf_{f \in \mathcal{F}} \mathcal{L}(f, \{X, Y\})$$

\mathcal{L} : ネットワークの入出力を変形する

\mathcal{F} : ネットワーク構造で決める




抽象的な“数学”を現実のタスクに応用可能にする

現実的にはtry-and-errorな調整がいっぱい必要.....


深層学習で物理現象をモデル化する

データから物理現象をモデル化し予測

- ミクロにシミュレーションすることは高コスト
- マクロなモデル化はどこかに近似が入る
 - ・分子動力学法の経験ポテンシャルなど



物理現象



物理シミュレーション



科学的発見や設計

深層学習で物理現象をモデル化する

目的汎関数 \mathcal{L} は何か？

[Chen+, NeurIPS2017]
[Teshima+, NeurIPS2020]

○微分方程式 $\dot{u} = f(u)$ で記述する
→ ベクトル場 f を近似する

万能近似性あり

○離散時刻でサンプルされ、 u は既知、 du/dt は未知
→ 初期値問題の解とデータの誤差を最小化

システム同定の枠組みが使える

随伴方程式を使って最適化したり

深層学習で物理現象をモデル化する

Neural ODE (NODE) によるモデル化

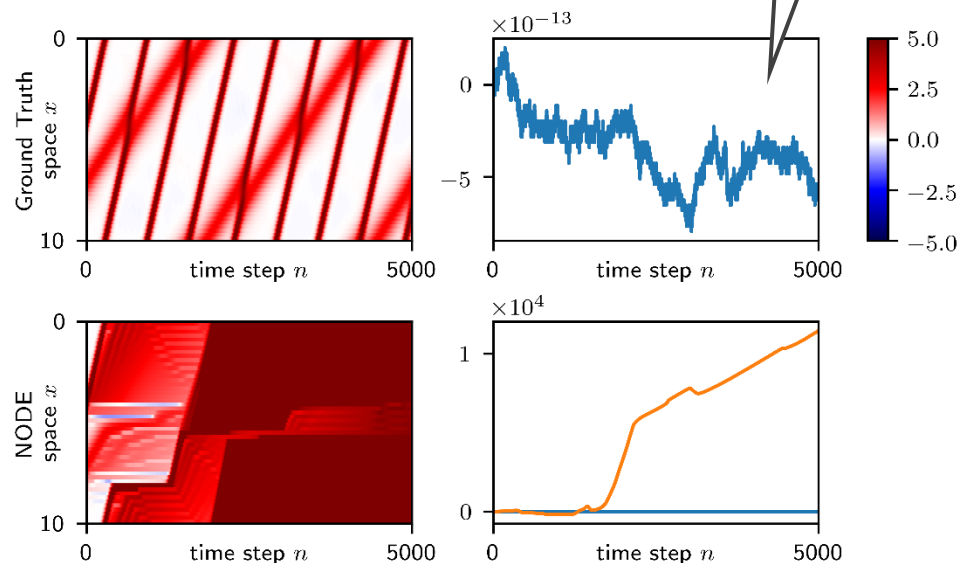
[Chen+, NeurIPS2017]

○ODE $\dot{u} = f(u)$ の f をニューラルネットワークで近似

KdV方程式


- 途中で崩壊する

エネルギー H



mass-spring system

- エネルギーが減衰する



深層学習で物理現象をモデル化する

関数空間 \mathcal{F} をハミルトン系に限定

○エネルギー関数 H を近似する

位置 q : $\dot{q} = \nabla_p H(q, p)$

正準運動量 p : $\dot{p} = -\nabla_q H(q, p)$

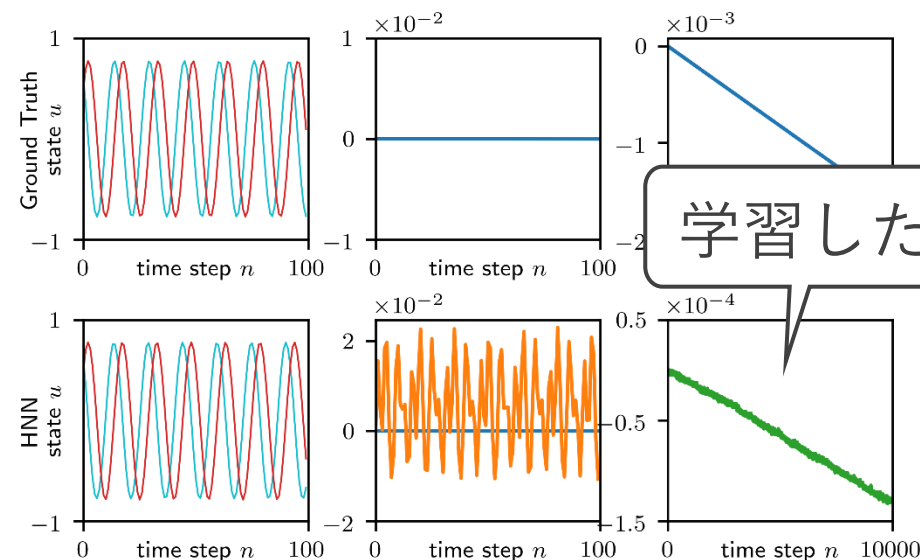
[Greydanus+, NeurIPS2019]

[Chen+, arXiv, 2021]

万能近似性あり

mass-spring system

• エネルギー関数 H が短期間保存



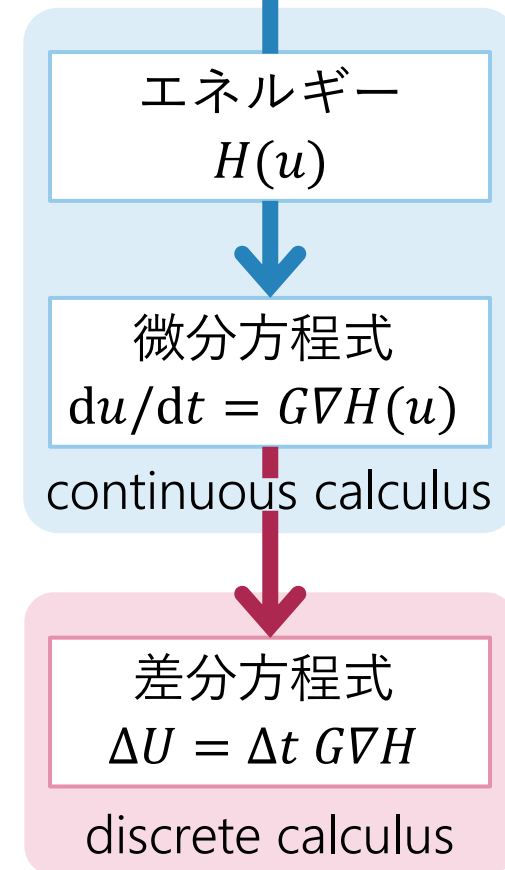

深層学習で物理現象をモデル化する

Hamiltonian Neural Network [Greydanus+, NeurIPS2019]

- エネルギー関数をニューラルネットワークで近似
- 連続時間でエネルギーを保存
- 数値積分するとエネルギーは保存しない

Symplectic HNN [Chen+, ICLR2020]

- シンプレクティック数値積分法を採用
- 修正エネルギーを保存(真のエネルギーは振動)
- 散逸系には使えない



提案手法

ハミルトン系 → エネルギーに基づくモデル化


- 保存系・散逸系の ODE と PDE に適応可能
- 一般のシンプレクティック勾配流・リーマン勾配流

数値積分 → 離散時間モデル化

- 離散時間で厳密なエネルギーの保存と散逸
- 離散化誤差を起こさない

深層学習に適応可能

- “自動離散微分”を提案



離散エネルギー
 $H(U)$

差分方程式
 $\Delta U = \Delta t \, G \nabla H$

discrete calculus

[Matsubara+, NeurIPS2020]


提案手法: エネルギーに基づくモデル化

多くの物理系はエネルギーでモデル化できる

$$du/dt = G \nabla H(u)$$

$$\text{ODE } u = (q \ p)^{\top}$$

$$\text{PDE } u = (u_1 \ \dots \ u_n)^{\top}$$



提案手法: エネルギーに基づくモデル化

多くの物理系はエネルギーでモデル化できる

$$du/dt = G \nabla H(u)$$

$$\text{ODE } u = (q \ p)^T$$

$$\text{PDE } u = (u_1 \ \dots \ u_n)^T$$

保存系


G : 歪対称行列

$$\begin{aligned} dH/dt &= \partial H / \partial u \cdot du/dt \\ &= \nabla H^T G \nabla H = 0 \end{aligned}$$

ハミルトン系

$$S = \begin{pmatrix} 0 & I \\ -I & 0 \end{pmatrix}$$

例: 分子動力学, 天体



提案手法: エネルギーに基づくモデル化

多くの物理系はエネルギーでモデル化できる

$$du/dt = G \nabla H(u)$$

$$\text{ODE } u = (q \ p)^T$$

$$\text{PDE } u = (u_1 \ \dots \ u_n)^T$$

保存系


G : 歪対称行列

$$dH/dt = \nabla H^T G \nabla H = 0$$

ハミルトン系

$$S = \begin{pmatrix} 0 & I \\ -I & 0 \end{pmatrix}$$

例: 分子動力学, 天体



散逸系

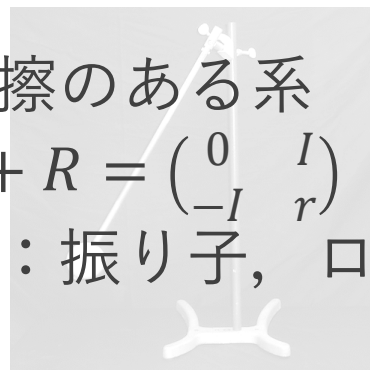
G : 半負定値行列

$$dH/dt = \nabla H^T G \nabla H \leq 0$$

摩擦のある系

$$S + R = \begin{pmatrix} 0 & I \\ -I & r \end{pmatrix}$$

例: 振り子, ロボット



提案手法: エネルギーに基づくモデル化

多くの物理系はエネルギーでモデル化できる

$$du/dt = G \nabla H(u)$$

保存系

G : 歪対称行列


$$dH/dt = \nabla H^\top G \nabla H = 0$$

$$\text{ODE } u = (q \ p)^\top$$

ハミルトン系

$$S = \begin{pmatrix} 0 & I \\ -I & 0 \end{pmatrix}$$

例: 分子動力学, 天体




$$\text{PDE } u = (u_1 \ \dots \ u_n)^\top$$

Hamiltonian field theory

$$D = \frac{1}{2\Delta x} \begin{pmatrix} 0 & 1 & \dots & & -1 \\ -1 & 0 & 1 & \dots & \\ \vdots & \ddots & \ddots & \ddots & \vdots \\ 1 & \dots & \dots & -1 & 0 & 1 \\ & & & -1 & 0 \end{pmatrix}$$

例: 波の方程式



散逸系

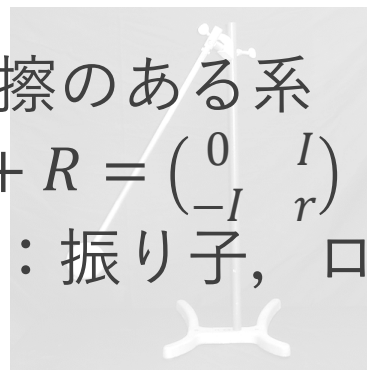
G : 半負定値行列

$$dH/dt = \nabla H^\top G \nabla H \leq 0$$

摩擦のある系

$$S + R = \begin{pmatrix} 0 & I \\ -I & r \end{pmatrix}$$

例: 振り子, ロボット



Landau free-energy theory

$$D_2 = \frac{1}{\Delta x^2} \begin{pmatrix} -2 & 1 & \dots & & 1 \\ 1 & -2 & 1 & \dots & \\ \vdots & \ddots & \ddots & \ddots & \vdots \\ 1 & \dots & \dots & 1 & -2 & 1 \\ & & & 1 & -2 \end{pmatrix}$$

例: 相分離, 亀裂形成



提案手法: 離散時間モデル化

連続時間システム

$$du/dt = G\nabla H(u)$$

連続時間の微積分

$$dH/dt = \nabla H \cdot du/dt = \nabla H^\top G \nabla H$$

$$\because \text{連鎖律 } dH = \nabla H \cdot du$$

G が歪対称なら保存系

G が半負定値なら散逸系

[Furihata+, Chapman and Hall/CRC, 2020]

提案手法: 離散時間モデル化

連続時間システム

$$du/dt = G \nabla H(u)$$

離散時間のシステム

$$\Delta u / \Delta t = \bar{G} \bar{\nabla} H(u_{n+1}, u_n)$$
$$\begin{cases} \Delta u = u_{n+1} - u_n \\ \Delta H = H(u_{n+1}) - H(u_n) \end{cases}$$

連続時間の微積分

$$dH/dt = \nabla H \cdot du/dt = \nabla H^\top G \nabla H$$

$$\because \text{連鎖律 } dH = \nabla H \cdot du$$

G が歪対称なら保存系

G が半負定値なら散逸系

[Furihata+, Chapman and Hall/CRC, 2020]

提案手法: 離散時間モデル化

連続時間システム

$$du/dt = G \nabla H(u)$$

連続時間の微積分

$$dH/dt = \nabla H \cdot du/dt = \nabla H^\top G \nabla H$$

$$\because \text{連鎖律 } dH = \nabla H \cdot du$$

離散時間のシステム

$$\Delta u / \Delta t = \bar{G} \bar{\nabla} H(u_{n+1}, u_n)$$

$$\begin{cases} \Delta u = u_{n+1} - u_n \\ \Delta H = H(u_{n+1}) - H(u_n) \end{cases}$$

離散時間の微積分

$$\Delta H / \Delta t = \bar{\nabla} H \cdot \Delta u / \Delta t = \bar{\nabla} H^\top \bar{G} \bar{\nabla} H$$

$$\because \text{連鎖律 } \Delta H = \bar{\nabla} H \cdot \Delta u$$

\bar{G} が歪対称なら保存系

\bar{G} が半負定値なら散逸系

[Furihata+, Chapman and Hall/CRC, 2020]

提案手法: 自動離散微分

連続時間の微積分

$$dH(u) = \nabla H(u) \cdot du \quad \text{連鎖律}$$

$$dH(ax; u) = a dH(x; u) \quad \text{線形性}$$

自動微分

出力層から逆伝播

$$\nabla(f \circ g)(u) = J_g(u)^\top \nabla f(g(u))$$

$$J_g = W$$

線形層

$$(J_g)_{kk} = \frac{\partial \sigma(u^{(k)})}{\partial u^{(k)}}$$

活性化関数

提案手法: 自動離散微分

連続時間の微積分

$$dH(u) = \nabla H(u) \cdot du \quad \text{連鎖律}$$

$$dH(ax; u) = a dH(x; u) \quad \text{線形性}$$

一貫性

離散時間の微積分

$$\Delta H(u_{n+1}, u_n) = \bar{\nabla} H(u_{n+1}, u_n) \cdot \Delta u$$

$$\bar{d}H(ax; u, v) = a \bar{d}H(x; u, v)$$

$$\bar{d}H(\cdot; u, u) = dH(\cdot; u)$$

自動微分

$$\nabla(f \circ g)(u) = J_g(u)^\top \nabla f(g(u))$$

$$J_g = W$$

$$(J_g)_{kk} = \frac{\partial \sigma(u^{(k)})}{\partial u^{(k)}}$$

自動離散微分



$$\bar{\nabla}(f \circ g)(u, v) = \bar{J}_g(u, v)^\top \bar{\nabla} f(g(u), g(v))$$

線形層

$$\bar{J}_g = W$$

$$\text{活性化関数 } (\bar{J}_g)_{kk} = \frac{\sigma(u^{(k)}) - \sigma(v^{(k)})}{u^{(k)} - v^{(k)}}$$

提案手法: 自動離散微分



自動微分

$$\nabla(f \circ g)(u) = J_g(u)^\top \nabla f(g(u))$$

$$J_g = W$$

$$(J_g)_{kk} = \frac{\partial \sigma(u^{(k)})}{\partial u^{(k)}}$$

自動離散微分

$$\bar{\nabla}(f \circ g)(u, v) = \bar{J}_g(u, v)^\top \bar{\nabla}f(g(u), g(v))$$

$$\text{線形層} \quad \bar{J}_g = W$$

$$\text{活性化関数} \quad (\bar{J}_g)_{kk} = \frac{\sigma(u^{(k)}) - \sigma(v^{(k)})}{u^{(k)} - v^{(k)}}$$

提案手法: 自動離散微分

離散時間システム

$$\Delta u / \Delta t = \bar{G} \bar{\nabla} H(u_{n+1}, u_n)$$
$$\begin{cases} \Delta u = u_{n+1} - u_n \\ \Delta H = H(u_{n+1}) - H(u_n) \end{cases}$$

離散時間の微積分

$$\Delta H / \Delta t = \bar{\nabla} H \cdot \Delta u / \Delta t = \bar{\nabla} H^\top \bar{G} \bar{\nabla} H$$

∴連鎖律 $\Delta H = \bar{\nabla} H \cdot \Delta u$

自動離散微分

$$\bar{\nabla}(f \circ g)(u, v) = \bar{J}_g(u, v)^\top \bar{\nabla} f(g(u), g(v))$$

$$\bar{J}_g = W$$

$$(\bar{J}_g)_{kk} = \frac{\sigma(u^{(k)}) - \sigma(v^{(k)})}{u^{(k)} - v^{(k)}}$$

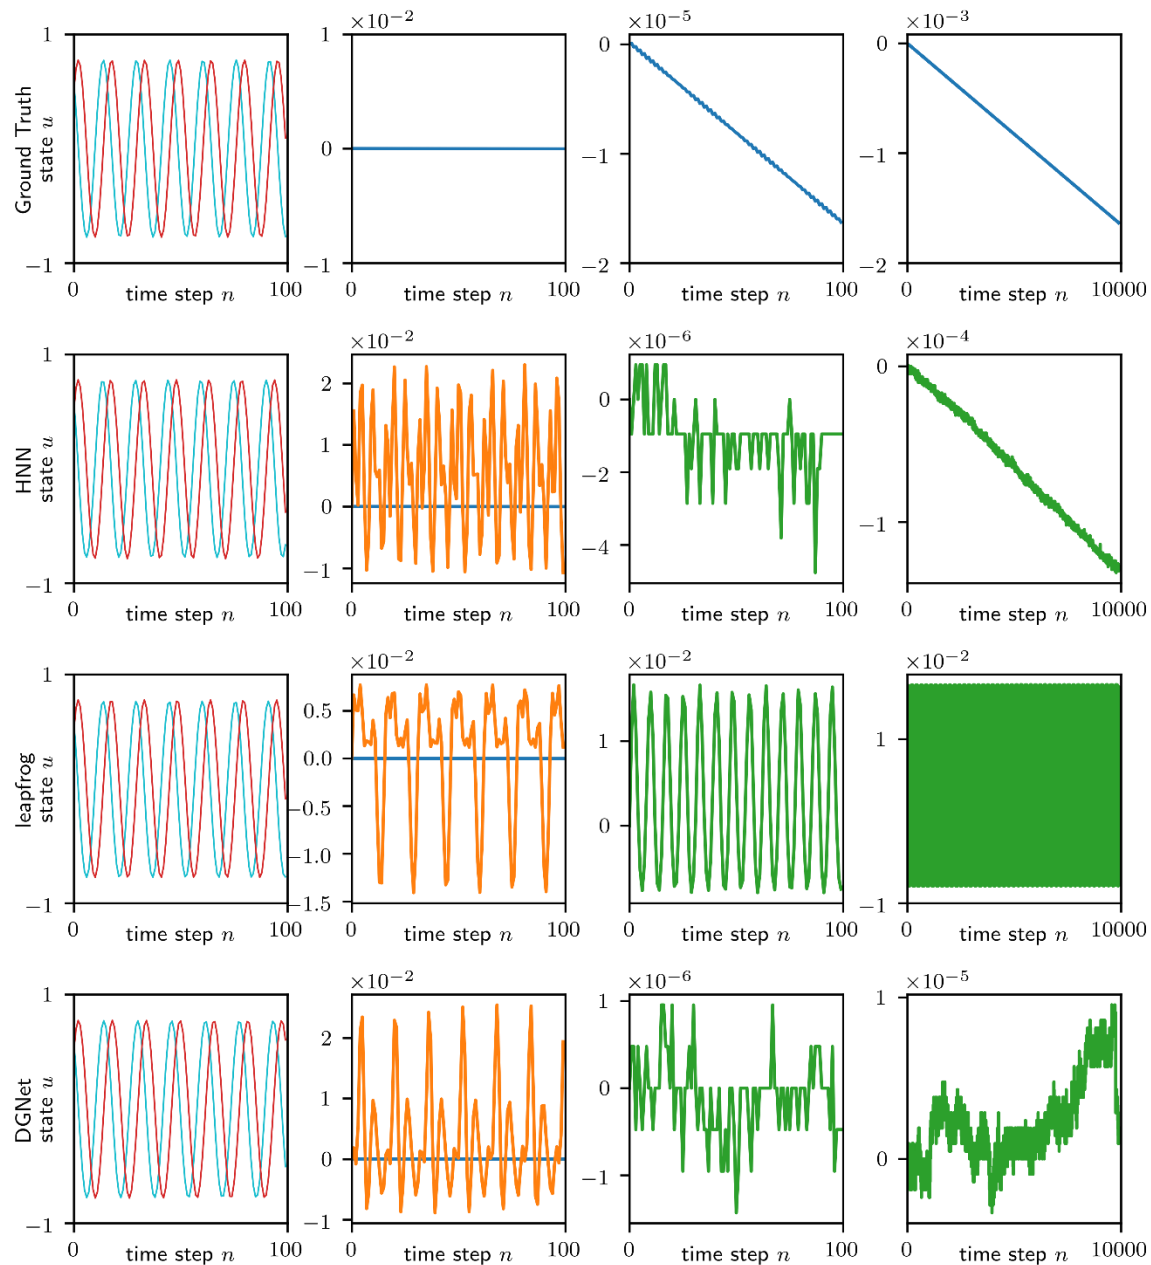
目的関数

$$\frac{1}{N} \|\Delta u / \Delta t - \bar{G} \bar{\nabla} H(u_{n+1}, u_n)\|^2$$

- 離散時間でモデル化されているので離散化誤差がない
- 学習は非常に速い(予測は陰的)

実験結果

mass-spring system
(保存系のODE)



3層のニューラルネットワーク
活性化関数はtanh

実験結果

KdV方程式
(保存系のPDE)

教師データ

$$\dot{u} = G \nabla H(u)$$




$$\frac{\Delta u}{\Delta t} = G \bar{\nabla} H(u_{n+1}, u_n)$$

(proposed)




畳み込み1層 + 全結合2層 + G の畳み込み

2-solitons

$t = 0$






-5.0 -2.5 0.0 2.5 5.0



状態

space x

time t



エネルギー

(モデル)

実験結果

畳み込み1層 + 全結合2層 + G の畳み込み

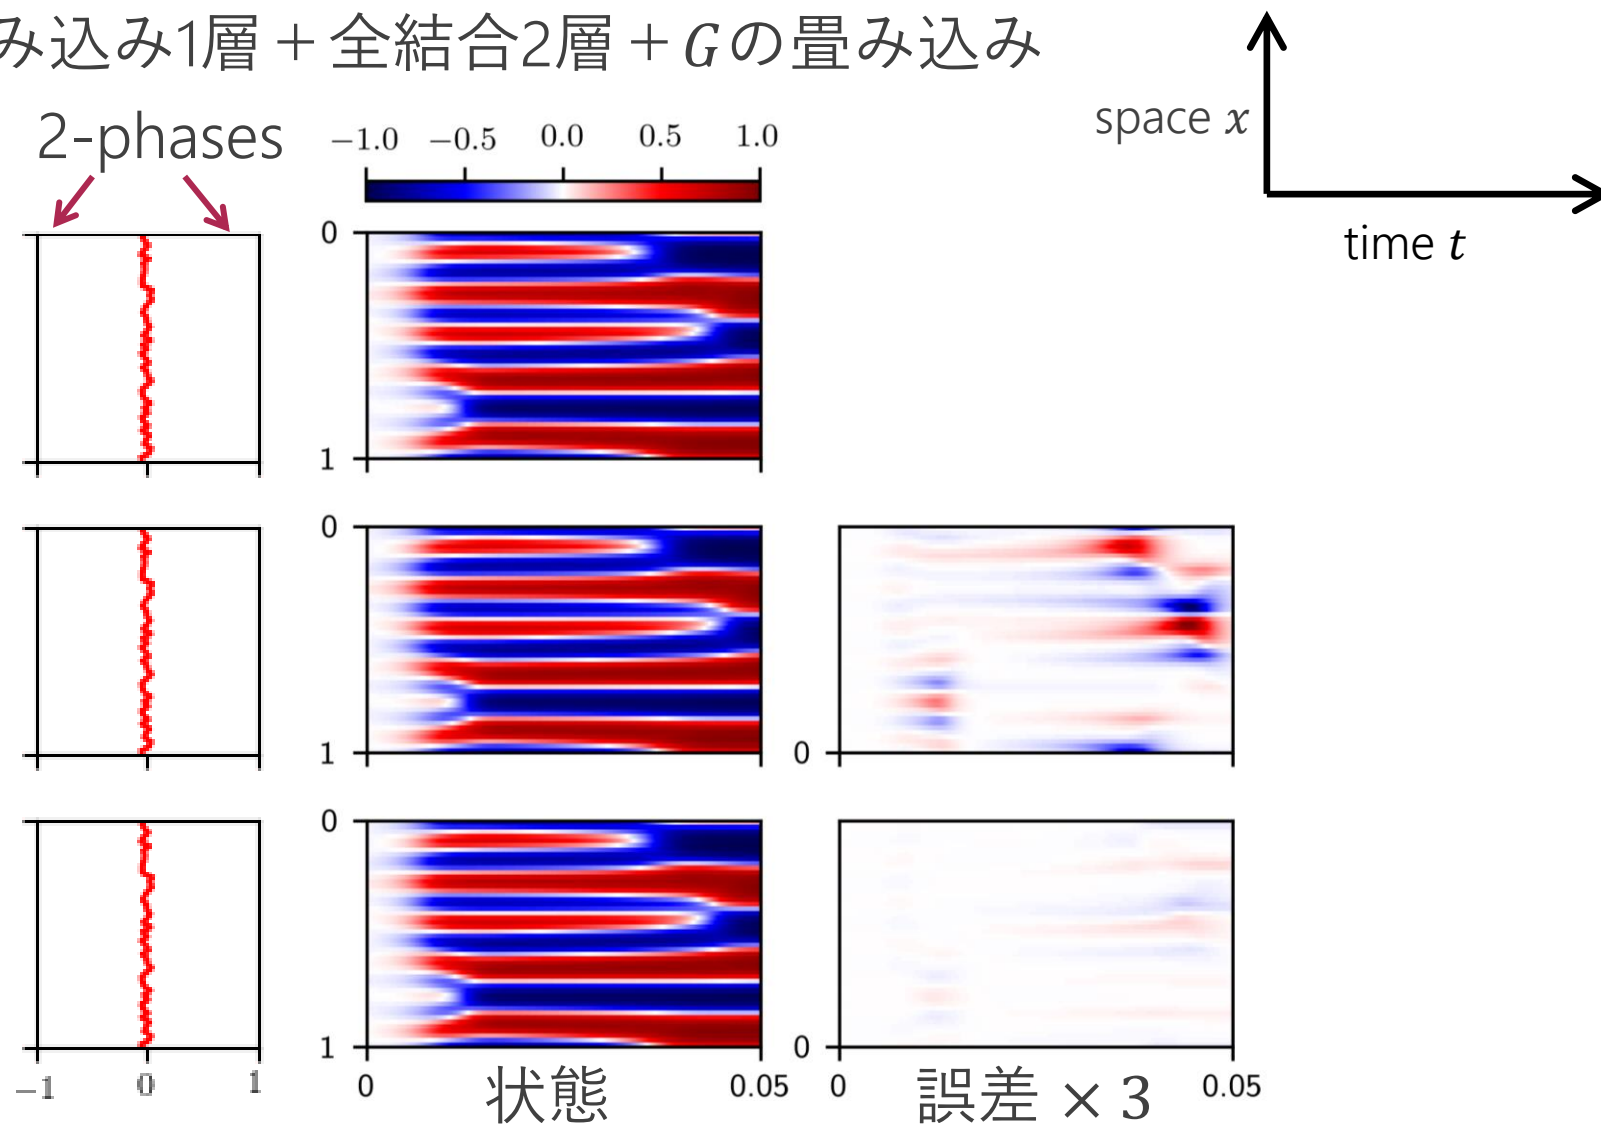
Cahn-Hilliard方程式
(散逸系のPDE)

教師データ

$$\dot{u} = G \nabla H(u)$$

$$\frac{\Delta u}{\Delta t} = G \bar{\nabla} H(u_{n+1}, u_n)$$

(proposed)



実験結果

二乗誤差（スケール調整済み）


手法	KdV方程式		Cahn-Hilliard方程式	
	エネルギー H	状態 u_n	エネルギー H	状態 u_n
$\dot{u} = f(u)$	>1000	>1000	>1000	913.96
$\dot{u} = G\nabla H(u)$	3.01	0.34	4.89	0.80
$\Delta u/\Delta t = G\bar{\nabla} H(u_{n+1}, u_n)$	1.60	0.25	0.34	0.07

4次の解法であるドルマン＝プリンス法よりも精度が高い

実験結果

2D Cahn-Hilliard方程式

(数値積分ではGPUのメモリに乗らなかった)



実験結果

2D Cahn-Hilliard方程式
(G を学習した)

$$G = \begin{pmatrix} 2.450 & 1.339 & 2.448 \\ 1.328 & -15.148 & 1.326 \\ 2.447 & 1.338 & 2.452 \end{pmatrix}$$

- 合計がゼロ
→ 質量が保存される
- 負定値行列である
→ エネルギー散逸性がある
- 回転・反転対称
→ 等方性がある

学習結果を解析すれば系の性質も分かる

提案手法のまとめ

ハミルトン系 → エネルギーに基づくモデル化


- 保存系・散逸系の ODE と PDE に適応可能
- 一般のシンプレクティック勾配流・リーマン勾配流

数値積分 → 離散時間モデル化

- 離散時間で厳密なエネルギーの保存と散逸
- 離散化誤差を起こさない

深層学習に適応可能

- “自動離散微分”を提案



離散エネルギー
 $H(U)$

差分方程式
 $\Delta U = \Delta t G \nabla H$

discrete calculus

[Matsubara+, NeurIPS2020]

深層学習とは

目的汎関数 \mathcal{L} と関数空間 \mathcal{F} を
目的に合わせて設計する研究領域である

$$\inf_{f \in \mathcal{F}} \mathcal{L}(f, \{X, Y\})$$

\mathcal{L} : 離散時間システムを近似する

\mathcal{F} : エネルギーに基づき(離散)勾配を使う
偏微分方程式は 3×3 カーネル1回で十分
微分可能で有界な活性化関数が良い

深層学習とは

目的汎関数 \mathcal{L} と関数空間 \mathcal{F} を
目的に合わせて設計する研究領域である

$$\inf_{f \in \mathcal{F}} \mathcal{L}(f, \{X, Y\})$$

$\mathcal{L} : ?$

$\mathcal{F} : ?$